



Софийски университет „Св. Кл. Охридски”

Факултет по математика и информатика

### Курсов Проект

на тема: „Рас-Man-AI”

Студент: **Владимир Войков Стоянов Ф.Н. 82284**

Курс: „КН курс 4 гр. 6“, Учебна година: 2023/24

Преподаватели: **проф. Иван Койчев:**


=====

Декларация за липса плагиатство:

- Плагиатство е да използваш, идеи, мнение или работа на друг, като претендираш, че са твои. Това е форма на преписване.
- Тази курсова работа е моя, като всички изречения, илюстрации и програми от други хора са изрично цитирани.
- Тази курсова работа или нейна версия не са представени в друг университет или друга учебна институция.
- Разбирам, че ако се установи плагиатство в работата ми ще получа оценка “Слаб”.

4.02.2024 г.

Подпис на студента:



Фигура 1. Играта Рас-Man

# Съдържание

<b>1 Увод</b>	<b>2</b>
<b>2 Общ преглед на областта: Стратегии и алгоритми за оптимална игра на Рас-Мат, базирана на ИИ</b>	<b>3</b>
Подходи и методи за решаване	3
Възможни подходи към разработването на Рас-Мат AI	4
<b>3 Проектиране</b>	<b>4</b>
Анализ на изискванията	4
Обща архитектура	5
Модел на данни	5
Схема на представяне на знанията	5
Потребителски интерфейс	5
<b>4 РЕАЛИЗАЦИЯ, ТЕСТВАНЕ/ЕКСПЕРИМЕНТИ</b>	<b>5</b>
Реализация (Внедряване)	5
Методологии за тестване	6
Експерименти и резултати	6
Използвани технологии, платформи и библиотеки	7
<b>5 Заключение</b>	<b>7</b>
БЪДЕЩО РАЗВИТИЕ	7
<b>6 Използвана литература</b>	<b>7</b>

## 1 Увод

Проектът Рас-Мaп е разработени за [CS 188 в университета в Бъркли](#). Целта е да се имплементират и приложат набор от AI техники за игра на Рас-Мaп. Този проект има за цел да вкара в употреба и сравни основни концепции за ИИ, като информирано търсене в пространството от състояния, машинно самообучение и др.

Идеалната цел на проекта е с помощта на ИИ агент да контролира героят Рас-мап по оптимален начин, за да спечели играта с възможно най-висок резултат.

## 2 Общ преглед на областта: Стратегии и алгоритми за оптимална игра на Рас-Мaп, базирана на ИИ

В сферата на изкуствения интелект и машинното самообучение (ML), разработването и внедряването на алгоритми за решаване на игри представлява завладяваща демонстрация за това как ИИ може да взаимодейства, анализира и навигира в сложни среди. Типичен пример за такова приложение е проектът за изкуствен интелект, базиран на класическата игра Рас-Мaп. Този проект показва разнообразие от алгоритми и стратегии, предназначени за навигация в лабиринти, оптимизиране на вземането на решения и подобряване на играта чрез интелигентно поведение на агента. Обхватът на проекта е в няколко ключови области, включително алгоритми за търсене, многоагентна координация и техники за машинно самообучение, всяка от които е пригодена за преодоляване на специфични предизвикателства в играта.

### *Подходи и методи за решаване*

- Алгоритми за търсене: алгоритми за неинформирано търсене като търсене в дълбочина (DFS), търсене в широчина (BFS), Uniform Cost Search (UCS) и за информирано - A\* са внедрени за насочване Рас-Мaп през лабиринти. Всеки алгоритъм предлага уникален подход към навигацията в лабиринта, показвайки своите силни страни и ограничения в различни конфигурации на лабиринти.
- Евристичен анализ: В контекста на A\* и други базирани на евристика търсения, разработването на ефективни евристики, като разстоянието Манхатън за обща навигация в лабиринта и по-специализирани евристики за събиране на храна и навигация в ъглите, са критични за оптимизиране на ефективността и ефективността на търсенето.
- Мултиагентни стратегии: Проектът се простира отвъд предизвикателствата на задачите с един агент, за да изследва динамиката на множество агенти. Разглеждайки стратегии като рефлексни агенти, които вземат [предвид близостта на храната, позициите на призраците и други фактори](#), демонстрират основно реактивно поведение. По-сложни подходи, като например алгоритми Minimax, се използват за стратегическо вземане на решения в присъствието на противникови агенти и налична пълна информация за тях.

- Приложения за машинно обучение: Техники за машинно обучение, по-специално Q-learning и Approximate Q-Learning, се прилагат за разработване на стратегии за игри, които се адаптират и подобряват чрез опит. Тези методи се фокусират върху оптимизирането на производителността на Рас-Ман в различни мрежови среди, демонстрирайки потенциала на ML в развиващите се стратегии за игри.

## **Възможни подходи към разработването на Рас-Ман AI**

### **1. Системи, базирани на правила**

- Евристични алгоритми за търсене
- Дървета на решенията

### **2. Обучение с подсилване (RL)**

- Q-learning: RL алгоритъм без модел, при който AI научава политика (policy), за да направи най-доброто действие въз основа на текущото състояние на играта, като увеличи максимално очакваната стойност на общата награда за всички следващи стъпки.
- Дълбоки Q-мрежи (DQN): Комбинира Q-learning с дълбоки невронни мрежи за обработка на сложни пространства

### **3. Еволюционни алгоритми**

- Генетични алгоритми: Симулиране на еволюцията чрез създаване на популация от Рас-Ман стратегии, които се развиват с течение на времето, избирайки стратегии, които имат по-висок резултат в играта.
- Невроеволюция (Neuroevolution): Използване на еволюционни алгоритми, за развиване на теглата на невронните мрежи, които контролират агента Рас-Ман, което потенциално води до ефективни стратегии.

### **4. Търсене на дървета в Монте Карло (MCTS)**

- Алгоритъм за вземане на решения, идеален за играта на Рас-Ман, където се симулират много прегравания на игра, за да вземат решения. MCTS балансира изследването на нови ходове с използването на ходове, за които знаем че са добри.

### **5. Учене с учител**

- Имитационно обучение: Обучава се невронна мрежа върху набор от добри човешки игра, с цел да имитира човешки стратегии.

## **3 Проектиране**

Дизайнът на програмата, визуализацията и обектно ориентираната част са предварително разработени и използвани наготово от [сайта за проекта](#).

### **Анализ на изискванията**

Основното изискване за проектът е да се реализират и сравнят различни подходи към задачата за оптимална игра на Рас-Ман. Необходимо изискване е

агент сам да взема решение какъв ход да предприеме с цел да изиграе оптимално играта.

## **Обща архитектура**

Архитектурата на системата е модулна и се състои от няколко ключови компонента:

- **AI Агенти:** Този модул включва различни AI агенти (напр. SearchAgents, ReflexAgent), които прилагат различни алгоритми и стратегии.
- **Алгоритми за търсене:** Колекция от алгоритми за търсене (DFS, BFS, UCS, A\*), предназначени за навигация в лабиринтите на играта.
- **Алгоритми за машинно самообучение:** Включва алгоритми за машинно обучение, като Q-learning и Approximate Q-Learning, за адаптивни стратегии за игра.
- **Дефиниции на проблеми:** Дефинира специфични задачи (напр. FoodSearchProblem, CornersProblem), които агентите трябва да навигират и разрешат.
- **Помощни програми:** Осигурява поддръжка за механиката на играта, визуализацията и взаимодействието, включително състоянието на играта, графиките и компонентите на потребителския интерфейс.

## **Модел на данни**

Моделът на данните за проектите на Pac-Man е съсредоточен около представянето на състоянието на играта, включително оформлението на лабиринта, позицията на Pac-Man, позициите на призраците, местоположенията на храната и резултатите. Този модел улеснява взаимодействието между AI агентите и средата на играта, позволявайки вземане на информирани решения и движение въз основа на текущото състояние.

## **Схема на представяне на знанията**

Знанията в системата се представя чрез комбинация от представяния на състояния, алгоритми и евристични функции.

## **Потребителски интерфейс**

Потребителският интерфейс е графичен, предоставяйки визуално представяне на дъската за игра Pac-Man. Той позволява наблюдение в реално време на поведението и взаимодействията на AI агентите в игровата среда.

## **4 Реализация, тестване/експерименти**

### **Реализация (Внедряване)**

Фазата на реализация включва внедряването на различни AI алгоритми, както е посочено в демонстрационния скрипт. Това включва алгоритми за търсене (DFS, BFS, UCS, A\*), евристични дизайни за A\* (напр. евристика за разстоянието в Манхатън), стратегии за справяне със специфични проблеми, като намиране на храна или навигиране до ъглите, и техники за засилване на обучението

(Q-learning и Приблизително Q-обучение). Всяко от тези изпълнения е предназначено да адресира определен аспект на играта, от основна навигация в лабиринта до сложно вземане на решения в присъствието на противници.

## **Методологии за тестване**

Тестването на всеки алгоритъм включва стартиране на играта Pac-Man със специфични параметри, които предизвикват AI агента да демонстрира своите способности. Процесът на тестване за всеки алгоритъм може да бъде разбит по следния начин:

- Алгоритми за търсене: Тествани в средни и големи лабиринти, за да се оцени ефективността им при намиране на път.
- Евристични функции: Ефективността на A\* с евристични функции се тества в сценарии, изискващи оптимално намиране на пътя и решаване на проблеми, като се използват параметри за указване на евристика
- Машинно обучение: Q-learning и Approximate Q-Learning се тестват в множество епизоди на различни размери на мрежата, като се фокусира върху способността на обучаващия се агент да подобри своята политика въз основа на опита.

Разбирането и реализацията на Q-learning алгоритмите се оповава на [статията](#).

## **Експерименти и резултати**

Експериментите, описани в сценария, демонстрират цялостна оценка на AI стратегии при различни условия. Основните констатации от тези експерименти включват:

- Ефективност при намиране на път: Сравнението между алгоритмите за търсене подчертава ефективността и ефективността на всеки метод, като A\* като цяло превъзхожда другите стратегии за търсене, когато е използвана подходяща евристика.
- Евристична ефективност: Прилагането на специфични за проблема евристики значително подобрява производителността на алгоритмите за търсене, намалявайки пространството за търсене и времето, необходимо за намиране на оптимални решения.
- Адаптивно обучение: Експериментите с машинно обучение илюстрират способността на агентите за обучение с подсилване да адаптират и оптимизират своите стратегии с течение на времето. Прогресията от първоначалните изпитания към по-късните епизоди демонстрира значително подобрение във вземането на решения и представянето на играта.

След проведените експерименти, най-добре се представя агентът, който взема решения на базата на политика генерирана след трениране на адаптивен Q-learning. Q-learning подхода също показва добри резултати, но след много по-голямо количество епизоди и съответно много повече време. Адаптивното Q-обучение превъзхожда традиционното Q-обучение в контекста на играта Pac-Man поради способността си да коригира стратегията си за обучение въз основа на динамиката и сложността на средата. Традиционното Q-обучение следва фиксирана скорост на учене и стратегия за изследване, която може да не е

оптимална във всички етапи на учене или във всяка ситуация, срещана в играта. За разлика от това, адаптивното Q-обучение променя своите параметри, като скоростта на обучение (learning rate) и скоростта на изследване (exploration rate). Основното предимство е адаптивността към промените в околната среда. В среди като играта Pac-Man, където пространството на състояния могат да варират значително от една стъпка до следваща, способността на Adaptive Q-learning да коригира своите параметри му позволява да реагира по-ефективно към нови или променящи се състояния в сравнение с традиционното Q-обучение, което използва статичен подход през целия учебен процес.

## ***Използвани технологии, платформи и библиотеки***

В проектът са използвани само и единствено библиотеки вградени в Python версия 3.6. Не са използвани външни библиотеки с имплементирани алгоритми.

**ВАЖНО** Проектът трябва да се изпълнява в среда с **Python 3.6**

## **5 Заключение**

Ефективност на търсенето: Сравняването на алгоритмите за търсене разкрива тяхната пригодност за различни сценарии на игра. Например, докато DFS и BFS предлагат основни възможности за търсене, тяхната производителност може да бъде надмината от UCS и A\* по отношение на оптималността на пътя и ефективността на търсене, особено в сложни лабиринти. Въпреки това подходът за машинно самообучение използващ адаптивен Q-learning надминава всички изброени опити от към производителност и резултати.

## ***Бъдещо развитие***

Естественото продължение на опитът е да се развие алгоритъм за трениране на Deep Q-learning.

Другите нереализирани подходи, споменати във [Възможни подходи към разработването на Pac-Man AI](#) също могат да бъдат развити и сравнени.

Една интересна задача за разработка би била оптимизирането на духовете (противниците) и тяхното поведение. Как това би променило моделите? Адаптивни ли са различните подходи?

## **6 Използвана литература**

[1] [Projects - CS 188: Introduction to Artificial Intelligence, Spring 2022](#)

[2] [Reinforcement Learning Explained Visually \(Part 4\): Q Learning, step-by-step | by Ketan Doshi](#)

[3] [PacMan: what kinds of heuristics are mainly used? - Stack Overflow](#)